



# K-MEANS

## APRENDIZAGEM DE MÁQUINA

### CST em Desenvolvimento de Software Multiplataforma



PROF. Me. TIAGO A. SILVA



# O QUE É K-MEANS?

- O k-means é um dos algoritmos mais conhecidos e utilizados para agrupamento (**clustering**) em aprendizado de máquina não supervisionado.
- Serve para separar dados em **k grupos** (clusters) com base em similaridade.



# O QUE É K-MEANS FAZ?

- Ele divide um conjunto de pontos em **k clusters**, de forma que:
  - Cada ponto é associado ao centróide (centro do cluster) mais próximo.
  - Os centróides são atualizados continuamente até que a solução fique estável.

# QUANDO USAR O K-MEANS?

- É usado quando queremos descobrir padrões sem rótulos, por exemplo:
  - **Segmentar clientes por comportamento.**
  - Agrupar documentos semelhantes.
  - Separar cores próximas em imagens.
  - Detectar padrões em dados biológicos.
  - Reduzir complexidade em processamento de imagens.


# COMO O K-MEANS FUNCIONA?

- 1) Escolha  $k$ , o número de clusters desejados.
- 2) Inicialize os centróides, normalmente escolhendo  $k$  pontos aleatórios.
- 3) Associação: cada ponto é associado ao centróide mais próximo (usando normalmente a distância Euclidiana).
- 4) Atualização: os centróides são recalculados como a média dos pontos associados.
- 5) Repetição: os passos 3 e 4 são repetidos até:
  - os centróides não mudarem mais, ou
  - atingir um número máximo de iterações.

## EXEMPLO DE RESULTADO APÓS AGRUPAMENTO

*Usando o dataset da aula: segmentação de clientes*

# AGRUPANDO DADOS COM K-MEANS



## IMPLEMENTAÇÃO DO CÓDIGO

*Código em Python usando apenas Numpy e  
Matplotlib*



# CÉLULA 1: IMPORTANDO AS BIBLIOTECAS E LOAD DO DATASET



Aula K-means - kmeans.ipynb

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 # -----
5 # 1. Ler dataset CSV
6 # -----
7 # Supondo que o arquivo esteja no mesmo diretório
8 X = np.genfromtxt("dataset_clientes_kmeans.csv", delimiter=",", skip_header=1)
```

# CÉLULA 2: DEFINIÇÃO DA FUNÇÃO DA DISTÂNCIA EUCLIDIANA



Aula K-means - kmeans.ipynb

```
1  # -----  
2  # 2. Função de distância euclidiana  
3  # -----  
4  def euclidean_distance(a, b):  
5      return np.sqrt(np.sum((a - b) ** 2, axis=1))
```

```
1  # -----
2  # 3. Implementação K-means
3  # -----
4  def kmeans(X, k=3, max_iter=100):
5      # 1. Inicializar centróides escolhendo k pontos aleatórios
6      idx = np.random.choice(len(X), k, replace=False)
7      centroids = X[idx]
8
9      for _ in range(max_iter):
10         # 2. Associação – escolher centróide mais próximo
11         clusters = [[] for _ in range(k)]
12         labels = np.zeros(len(X))
13
14         for i, point in enumerate(X):
15             distances = euclidean_distance(point, centroids)
16             label = np.argmin(distances)
17             clusters[label].append(point)
18             labels[i] = label
19
20         # 3. Guardar centróides antigos
21         old_centroids = centroids.copy()
22
23         # 4. Atualizar centróides
24         for i in range(k):
25             if clusters[i]:
26                 centroids[i] = np.mean(clusters[i], axis=0)
27
28         # 5. Critério de parada
29         if np.allclose(centroids, old_centroids):
30             break
31
32     return centroids, labels
```

## CÉLULA 3: IMPLEMENTAÇÃO DO K-MEANS

# CÉLULA 4: CHAMADA DA FUNÇÃO K-MEANS

● ● ● Aula K-means - kmeans.ipynb


```
1  # -----  
2  # 4. Executar o k-means  
3  # -----  
4  centroids, labels = kmeans(X, k=3)
```

# CÉLULA 5: CONFIGURAÇÃO DO PLOT DO GRÁFICO

```
Aula K-means - kmeans.ipynb

1 # -----
2 # 5. Plotar resultados
3 # -----
4 plt.figure(figsize=(10, 6))
5
6 for cluster_id in np.unique(labels):
7     plt.scatter(
8         X[labels == cluster_id, 0],
9         X[labels == cluster_id, 1],
10        alpha=0.7,
11        label=f"Cluster {int(cluster_id)}"
12    )
13
14 plt.scatter(
15     centroids[:, 0], centroids[:, 1], s=180, c="black", marker="X", label="Centróides"
16 )
17
18 plt.title("Segmentação de Clientes com K-Means")
19 plt.xlabel("Frequência de Compras / mês")
20 plt.ylabel("Ticket Médio (R$)")
21 plt.legend()
22 plt.grid(True)
23 plt.show()
```

# RESULTADO DO PLOT



# OBRIGADO!

- Encontre este **material on-line** em:
  - Slides: Plataforma Google Classroom
- Em caso de **dúvidas**, entre em contato:
  - **Prof. Tiago:** [tiago.silva@cps.sp.gov.br](mailto:tiago.silva@cps.sp.gov.br)

